

Báo cáo Tuần 3 — Rider Acceptance Prediction

Thời gian: 03/08–09/08/2026

Nội dung: Đóng khung bài toán Post-Dispatch, xây dựng pipeline training tái lập, benchmark công bằng các model class, calibration và final audit.

Kết quả cuối tuần: V3 là **CatBoost** trên 22 feature Post-Dispatch của W2; model được chọn bằng 3 rolling folds theo thời gian, sau đó khóa calibration/threshold trước khi audit một lần ngày 13/07.

1. Mục tiêu

Tuần 3 trả lời bốn câu hỏi: (1) có nên tách riêng bài toán Post-Dispatch hay tiếp tục train một model combined, (2) model class nào phù hợp nhất với feature tabular đã xây dựng ở W2, (3) có cần xử lý imbalance/calibration hay bổ sung weather feature hay không, và (4) với một capacity can thiệp cố định, threshold nào có thể dùng trong vận hành.

Target vẫn là y_{accept} , trong đó $1 = \text{accept/completed}$ và $0 = \text{cancel}$. Model xuất xác suất $P(\text{accept})$; khi đánh giá cancel, sử dụng $P(\text{cancel}) = 1 - P(\text{accept})$. Metric quyết định là **Cancel PR-AUC** vì cancel chỉ chiếm khoảng 9,5% dữ liệu; ROC-AUC, Accept PR-AUC, LogLoss, Brier Score và ECE được giữ để kiểm tra đầy đủ ranking và chất lượng xác suất. Accuracy không được dùng để chọn model.

Khác với tuần 2, `is_post_dispatch` không còn là feature trong model. Nó chỉ là điều kiện lọc population để model dự báo đúng decision point sau khi dispatch.

2. Dữ liệu và thiết kế đánh giá

1 — Đóng khung population và temporal split


Pipeline tiếp tục sử dụng `orders_30d.parquet` và `customer_daily_30d.parquet`. Feature contract của W2 được giữ cố định, nhưng bỏ cờ phase `is_post_dispatch`; vì vậy V3 dùng **22 feature Post-Dispatch**. Các feature history rider đều được tạo point-in-time, chỉ dùng thông tin có trước thời điểm order.

Mọi lựa chọn model đều dùng split theo thời gian, không random split. Với ngày score cuối cùng D , pipeline dùng $D-30$ đến $D-2$ để train, $D-1$ cho validation/early stopping và chỉ score trên D . Ba rolling folds 09–11/07 dùng để tune và chọn champion; 12/07 dành riêng cho calibration/threshold; 13/07 là locked audit, không dùng để tune lại model hoặc feature.


Tập / giai đoạn	Thời gian và vai trò	Số order Post-Dispatch
Rolling fold 1	Train đến 07/07 → validation 08/07 → test 09/07	train 203.342; validation/test 8.478
Rolling fold 2	Train đến 08/07 → validation 09/07 → test 10/07	train tăng theo cửa sổ; validation/test tăng theo ngày
Rolling fold 3	Train đến 09/07 → validation 10/07 → test 11/07	train 220.334; validation/test 9.217
Calibration	12/07, chọn calibrator và threshold	tập riêng, không dùng chọn model class
Locked audit	13/07	8.609 = 792 cancel + 7.817 accept

2 — Pipeline training tái lập


Pipeline có một luồng thống nhất: build feature contract → lọc Post-Dispatch → temporal split → Optuna/train → rolling benchmark → calibration → threshold policy → final audit → MLflow/demo. Sơ đồ dưới là blueprint code sinh bằng `sklearn.utils.estimator_html_repr`; nó minh họa preprocessing và estimator, còn temporal split/audit được orchestration ở pipeline bên ngoài.




Hình 1.1 — Training pipeline LightGBM: feature contract native categorical → `LGBMClassifier`.




Hình 1.2 — Training pipeline XGBoost: feature contract native categorical → `XGBClassifier`.



Hình 1.3 — Training pipeline CatBoost: feature contract native categorical → `CatBoostClassifier`.



Hình 1.4 — Training pipeline MLP: numeric median-impute/standardize, categorical missing-impute/one-hot encode → PyTorch MLP.



Hình 1.5 — Training pipeline FT-Transformer: FoldEncoder (numeric standardization, categorical index) → Transformer model. Đây là research pipeline độc lập, không thay đổi V3 đã audit.

```

=====
                        W3 LOG — FRAMING / TEMPORAL SPLIT
=====
$ python -m model.V3.train --stage benchmark
[PASS] feature_contract = V1.3_post_only_22 | feature_count = 22
[PASS] is_post_dispatch is excluded from model features
[PASS] rolling_folds = fold_1(07-08-09), fold_2(08-09-10), fold_3(09-10-11)
[PASS] calibration_day_reserved = 2026-07-12 | audit_test_opened = false
[PASS] split_policy = time-based; random_split = false
Evidence: model/V3/artifacts/contracts/ and task3_fair_hpo/fair_hpo_30x4_v2/
=====
  
```

Hình 2 — Log feature contract, rolling temporal split và trạng thái audit chưa mở.

3. Có nên tách Post-Dispatch?

Ba setup LightGBM được score trên cùng 8.609 order audit để xác minh framing. Setup A là model combined kế thừa W2; setup B bỏ phase flag nhưng vẫn train combined; setup C chỉ train population Post-Dispatch bằng 22 feature. Bảng này dùng để xác minh framing, không dùng để chọn CatBoost champion.

Setup	Population train	Feature	ROC-AUC	Cancel PR-AUC	LogLoss	Brier	ECE	Quyết định
A — Combined control	Pre + Post	23	0,7457	0,2642	0,2706	0,0762	0,0044	Đối chứng
B — Combined, bỏ phase flag	Pre + Post	22	0,7440	0,2614	0,2711	0,0763	0,0053	Loại
C — Post-only	Post-only	22	0,7457	0,2641	0,2704	0,0762	0,0060	Chọn framing

Combined control và Post-only gần tương đương về metric. Tuy nhiên, Post-only đúng thời điểm can thiệp nghiệp vụ, không cho model dựa vào phase flag để phân biệt population và tạo ra một feature contract rõ ràng cho serving. Vì vậy toàn bộ benchmark model class phía sau dùng setup C.

4. Từ LightGBM baseline đến benchmark công bằng 5 model class

LightGBM V2 được Optuna tune trước làm baseline. Sau 30 trials trên ba rolling folds, Cancel PR-AUC tăng từ 0,3083 lên 0,3110; ROC-AUC tăng từ 0,7400 lên 0,7418; LogLoss/Brier/ECE đều giảm. Tuy nhiên LightGBM chưa thể được chọn champion tại bước này vì XGBoost, CatBoost và MLP chưa có cùng budget HPO.

```
=====
                        W3 LOG - LIGHTGBM BASELINE OPTUNA
=====
$ python -m model.V3.train --stage tune-lightgbm
study = w3_lightgbm_tuning | sampler = TPE | n_trials = 30
objective = rolling_mean_cancel_pr_auc | folds = 3
control_cancel_pr_auc = 0.3083
best_tuned_cancel_pr_auc = 0.3110 | uplift = +0.0027
logloss = 0.3177 → 0.3170 | brier = 0.09313 → 0.09293 | ece = 0.01620 → 0.01503
status = PASS | audit_test_opened = false
=====
```

Hình 3 — Log tuning LightGBM V2.

Metric rolling	LightGBM trước Optuna	LightGBM V2 sau 30 trials	Thay đổi
ROC-AUC	0,7400	0,7418	+0,0018
Cancel PR-AUC	0,3083	0,3110	+0,0027
LogLoss	0,3177	0,3170	-0,0007
Brier	0,09313	0,09293	-0,00020
ECE	0,01620	0,01503	-0,00117

Bảng 3 — Tác động riêng của Optuna lên LightGBM baseline.

Uplift Cancel PR-AUC xuất hiện trên cả ba folds (+0,0046; +0,0013; +0,0022), nên baseline tuned được giữ để làm mốc công bằng cho challenger.

Benchmark đầu tiên không được dùng để chọn champion vì LightGBM đã được Optuna tune, trong khi challenger chưa dùng budget tương đương; chênh CatBoost–LightGBM khi đó chỉ 0,00153, nhỏ hơn độ lệch chuẩn rolling xấp xỉ 0,042. Vì vậy, LightGBM, XGBoost, CatBoost và MLP được chạy lại với cùng 22 feature, cùng ba rolling folds, objective rolling mean Cancel PR-AUC và 30 Optuna trials/model. FT-Transformer được thử sau khi V3 đã khóa, cũng với feature contract/folds/objective và 30 trials CUDA; đây là nghiên cứu bổ sung để kiểm tra hướng Transformer, không mở lại audit hoặc thay đổi quyết định đã khóa.

Model class	Trials	Rolling Cancel PR-AUC (mean ± std)	ROC-AUC	Accept PR-AUC	LogLoss	Brier	ECE	Train 3 folds	Inference 3 folds	Quyết định
CatBoost	30	0,3158 ± 0,0420	0,7416	0,9527	0,3167	0,0927	0,0146	218,10s	0,063s	Champion V3
LightGBM	30	0,3114 ± 0,0435	0,7418	0,9530	0,3170	0,0929	0,0146	5,44s	0,115s	Baseline/runner-up
XGBoost	30	0,3110 ± 0,0429	0,7431	0,9533	0,3169	0,0930	0,0157	36,43s	0,040s	Không promote

FT-Transformer (CUDA)	30	0,3059 ± 0,0428	0,7375	0,9520	0,3187	0,0933	0,0124	111,25s	0,079s	Không promote
MLP	30	0,2967 ± 0,0392	0,7354	0,9516	0,3199	0,0939	0,0150	43,39s	0,007s	Không promote

CatBoost cao hơn LightGBM **0,00437 Cancel PR-AUC** và thắng cả 3/3 rolling folds, vượt rule promote: uplift ít nhất 0,003 và thắng tối thiểu 2/3 folds. XGBoost có ROC-AUC/Accept PR-AUC cao nhất nhưng không thắng metric cần cho nhóm cancel. FT-Transformer có ECE tốt nhất, nhưng thấp hơn CatBoost 0,00987 Cancel PR-AUC và không thắng fold nào. Với feature tabular hiện có, boosting tree phù hợp hơn MLP/Transformer.

Rolling scoring day	LightGBM	XGBoost	CatBoost	MLP	Winner theo Cancel PR-AUC
09/07	0,3576	0,3532	**0,3609**	0,3362	CatBoost
10/07	0,3236	**0,3275**	0,3267	0,3106	XGBoost
11/07	0,2531	0,2522	**0,2598**	0,2433	CatBoost

Bảng 5 — Bảng chứng stability theo từng fold của fair HPO.


CatBoost cao hơn LightGBM ở cả 3/3 folds; một fold XGBoost dẫn đầu toàn bộ model nhưng không đủ để vượt CatBoost trên mean objective hay rule stability.

Trade-off là CatBoost train chậm hơn LightGBM. Timing rolling replay của CatBoost khoảng 72,70s/fold, trong khi LightGBM khoảng 1,81s/fold. V3 ưu tiên cancel ranking theo mục tiêu bài toán; LightGBM vẫn là fallback nếu production có SLO training rất chặt.


```
=====
W3 LOG - 5 MODEL CLASS COMPARISON
=====
$ python -m model.V3.demo_week3 --no-open-ui
comparison_protocol = same_22_features | same_3_rolling_folds | objective = cancel_pr_auc
optuna_budget = 30 trials/model | models = CatBoost, LightGBM, XGBoost, FT-Transformer, MLP
CatBoost      rolling_cancel_pr_auc = 0.3158 | decision = CHAMPION
LightGBM      rolling_cancel_pr_auc = 0.3114 | decision = BASELINE
XGBoost       rolling_cancel_pr_auc = 0.3110 | decision = NOT_PROMOTED
FT-Transformer rolling_cancel_pr_auc = 0.3059 | decision = NOT_PROMOTED
MLP           rolling_cancel_pr_auc = 0.2967 | decision = NOT_PROMOTED
status = PASS | audit_test_reopened = false | one comparison table + one comparison log
=====
```

Hình 4 — Log tổng hợp duy nhất của benchmark 5 model class.

W3 — Benchmark 5 model class: primary objective và training cost



Biểu đồ 2 — ROC-AUC và chi phí training của 5 model class trên cùng rolling protocol. Trục thời gian dùng log scale vì LightGBM mất 5,44 giây còn CatBoost 218,10 giây cho ba folds. Biểu đồ này chỉ trình bày trade-off; champion vẫn được chọn theo Cancel PR-AUC, không theo ROC-AUC hay thời gian train.




Hình 5 — Dashboard MLflow của benchmark 5 model class.

5. Imbalance, calibration và threshold policy

Cancel rate trên các train folds là 9,50–9,62%. Đã thử `class_weight/scale_pos_weight` cho tree và MLP, focal loss cho MLP, luôn đánh giá trên natural distribution. Các kỹ thuật weighting có thể thay đổi precision/recall tại một threshold, nhưng không tạo được cải thiện tổng thể về ranking và làm xác suất quá tự tin hơn.

Kỹ thuật	Cancel PR-AUC trước → sau	Ảnh hưởng calibration	Quyết định
LightGBM balanced weight	0,3110 → 0,3064	ECE xấu tới 0,3186	Loại
XGBoost balanced weight	0,3086 → 0,2988	ECE xấu tới 0,3092	Loại
CatBoost balanced weight	0,3125 → 0,3103	ECE xấu tới 0,3238	Loại
MLP balanced weight	0,2852 → 0,2991	ECE xấu tới 0,3302	Loại
MLP focal loss	0,2852 → 0,3010	LogLoss/Brier/ECE = 0,4975 / 0,1602 / 0,2492	Không dùng
MLP focal + Platt	0,3010 → 0,2576	Calibration tốt hơn nhưng mất ranking	Không dùng

W3 — LightGBM class-weight ablation trên 3 rolling folds




Biểu đồ 3 — Ablation class weight trên LightGBM. Weighted model không cải thiện Cancel PR-AUC (0,3110 → 0,3064) nhưng làm Brier và ECE xấu đi mạnh. W3 không lưu hard prediction của từng ablation tại một threshold cố định, nên không đưa

Recall@0,5 vào biểu đồ để tránh báo cáo một chỉ số không có evidence; yêu cầu mentor về PR-AUC và calibration vẫn được đo đầy đủ.

Calibration trên tập riêng D-1 (12/07)

Calibration được fit riêng trên ngày 12/07, sau khi chọn provisional champion bằng rolling folds 09–11/07 và trước khi mở audit 13/07. Evaluation dùng 5-fold out-of-fold trên chính tập calibration; không fit calibrator trên audit. Ba phương án mentor yêu cầu đều đã thử với CatBoost: Platt scaling, Isotonic regression và SplineCalib. Raw probability (None) là control bắt buộc.

Calibration method	ROC-AUC	Accept PR-AUC	Cancel PR-AUC	LogLoss	Brier	ECE	Quyết định
None / raw	0,7196	0,9542	0,2635	0,2997	0,0857	0,0045	Giữ
Platt scaling	0,7183	0,9535	0,2622	0,3059	0,0865	0,0190	Loại
Isotonic regression	0,7081	0,9505	0,2467	0,3143	0,0862	0,0075	Loại
SplineCalib	0,7178	0,9533	0,2537	0,3044	0,0864	0,0065	Loại



Biểu đồ 4 — Reliability curve OOF trước/sau calibration. Raw CatBoost được giữ vì các calibrator không cải thiện đủ ranking và probability quality.

Lưu ý: đây không phải bằng benchmark model class. Đây là kết quả của một stage calibration độc lập trên D-1, chỉ dùng để quyết định mapping xác suất và threshold trước khi mở audit. Vì raw/None được chọn, V3 vẫn đi qua đầy đủ bước calibration nhưng không áp thêm một calibrator vào xác suất cuối.

Threshold không được chọn theo Max-F1 mà theo capacity can thiệp. Trên calibration day, các order được sắp xếp theo p_cancel giảm dần; threshold gần capacity mục tiêu được chọn rồi kiểm tra precision, recall và FPR. Policy 5% được khóa trước audit.

Policy	Threshold	Alert rate	Precision	Recall	FPR	TP / FP / FN / TN	Quyết định
--------	-----------	------------	-----------	--------	-----	-------------------	------------

Max-F1 reference	≥ 0,17	15,22%	25,99%	38,18%	12,56%	307 / 874 / 497 / 6.083	Không dùng
Capacity 3%	≥ 0,31	2,94%	42,11%	11,94%	1,90%	96 / 132 / 708 / 6.825	Tham khảo
Capacity 5%	≥ 0,27	4,51%	36,86%	16,04%	3,18%	129 / 221 / 675 / 6.736	Khóa V3
Capacity 10%	≥ 0,21	9,17%	29,35%	26,00%	7,23%	209 / 503 / 595 / 6.454	Tham khảo
Capacity 20%	≥ 0,15	19,71%	23,14%	44,03%	16,90%	354 / 1.176 / 450 / 5.781	Không dùng

```

=====
W3 LOG - CALIBRATION / THRESHOLD LOCK
=====
$ python -m model.V3.train --stage calibration
calibration_day = 2026-07-12 | candidates = raw, platt, isotonic, spline
selected_calibrator = none (raw CatBoost has best OOF Brier/ECE and ranking)
$ python -m model.V3.train --stage threshold-policy
capacity_policy = 5% | threshold_p_cancel = 0.27
calibration/threshold artifacts are written before opening the 13/07 audit
status = PASS | audit_test_opened = false
=====

```


Hình 6 — Log calibration và threshold lock trước audit.

6. Kết quả V3 trên locked audit

Sau khi khóa **CatBoost + 22 feature + no class weight + calibration decision: `None/raw`** (sau khi evaluate Platt, Isotonic và SplineCalib trên tập riêng 12/07) + **`p\_cancel ≥ 0,27`**, audit 13/07 được mở đúng một lần. V3 cải thiện đồng thời ranking và probability quality so với V0 và model W2 final trên cùng 8.609 order Post-Dispatch.


Metric audit 13/07	V0 baseline	V1.3 / W2 final	V3 CatBoost	Thay đổi V3 vs V0
ROC-AUC	0,7267	0,7420	0,7483	+0,0216
Accept PR-AUC	0,9612	0,9635	0,9646	+0,0034
Cancel PR-AUC	0,2350	0,2594	0,2709	+0,0359
LogLoss	0,2765	0,2717	0,2691	-0,0074
Brier	0,0777	0,0764	0,0759	-0,0018
ECE	0,0077	0,0066	0,0056	-0,0021

V3 CatBoost — Discrimination on locked audit 13/07 (n = 8,609)



Biểu đồ 5 — ROC curve và Precision–Recall curve của V3 CatBoost trên audit. Hai curve sử dụng nhãn cancel và `p\_cancel`. ROC-AUC đạt 0,7483; Cancel PR-AUC đạt 0,2709. Đường ngang trong Precision–Recall curve là cancel prevalence 9,20%, cho thấy precision của model vượt đáng kể mức random ranking.


V3 CatBoost audit reliability



Biểu đồ 6 — Reliability curve của V3 CatBoost trên locked audit.


Tại threshold đã khóa, model phát 366 cảnh báo (4,25% order); precision cancel 35,52%, recall 16,41% và FPR 3,02%. Threshold này là policy giới hạn nguồn lực, không phải ngưỡng để tối đa F1.

Thực tế / Dự báo tại `p_cancel ≥ 0,27`	Không cảnh báo cancel	Cảnh báo cancel
Không cancel	TN = 7.581	FP = 236
Cancel	FN = 662	TP = 130




Biểu đồ 7 — Confusion matrix V3 CatBoost trên audit.

— 0 — Cancelled — 1 — Completed --- V3: $p_{cancel} \geq 0.27 \rightarrow p_{accept} \leq 0.73$
Separation of predicted probabilities by actual label — V0 vs V1.3 vs V3
Common Post-Dispatch keys: 8,609 | y=0 Cancelled, y=1 Completed



Biểu đồ 8 — Phân phối xác suất theo nhãn thật, chuẩn hóa theo từng lớp. V3 dùng đường threshold vận hành $p_{accept} \leq 0.73$, tương đương $p_{cancel} \geq 0.27$; V0/V1.3 chỉ hiển thị mốc tham chiếu 0,50. Biểu đồ được dùng để quan sát khả năng tách nhãn, còn kết luận model vẫn dựa trên ROC-AUC và Cancel PR-AUC.

— 0 — Cancelled — 1 — Completed --- V3: $p_{cancel} \geq 0.27 \rightarrow p_{accept} \leq 0.73$
Separation of predicted probabilities by actual label — V0 vs V1.3 vs V3
Common Post-Dispatch keys: 8,609 | y=0 Cancelled, y=1 Completed



Biểu đồ 9 — Phân phối raw count theo nhãn thật. Biểu đồ xác nhận sự lệch lớp 792 cancel so với 7.817 accept, vì vậy raw count không được dùng đơn lẻ để kết luận chất lượng model.

```
=====
W3 LOG – FINAL PIPELINE LOCK / AUDIT
=====
$ python -m model.V3.train --stage final-audit
locked_model = CatBoost | features = 22 | class_weight = none | calibrator = none
threshold = p_cancel >= 0.27 | audit_day = 2026-07-13
audit_test_opened = true (one-time immutable run)
ROC-AUC=0.7483 | Cancel PR-AUC=0.2709 | LogLoss=0.2691 | Brier=0.0759 | ECE=0.0056
confusion: TP=130 | FP=236 | FN=662 | TN=7581 | status = PASS
=====
```

Hình 7 — Log khóa pipeline và one-time audit.

7. Nghiên cứu feature weather và đánh giá theo pain segment

Weather được kiểm tra như hướng optional, tách khỏi benchmark model class để không nhầm uplift của feature với uplift của algorithm. Các candidate daily lag, derived daily và hourly/event, gồm `is_rainy_3h`, được join theo pickup/time point-in-time. Nguồn reanalysis vẫn được gắn `offline_research_only` vì chưa chứng minh `weather_available_at ≤ order_datetime` trong serving.

Hướng thử	Số candidate	Kết quả	Quyết định
Daily lag D-1	8	Δ Cancel PR-AUC từ -0,0003 đến -0,0019	Loại
Derived daily	15	Δ từ 0,0000 đến -0,0018; metric probability xấu hơn	Loại
Hourly/event, gồm <code>`is_rainy_3h`</code>	Nhiều candidate	Không candidate qua gate uplift/stability	Loại

Rule giữ feature là Δ Cancel PR-AUC $\geq 0,001$, ROC không giảm, LogLoss/Brier không tăng và cải thiện ít nhất 2/3 folds. Không feature weather nào đạt rule, vì vậy không thêm weather vào V3. Kết quả khác với một feature set/protocol khác không đủ lý do để giữ feature trong pipeline này.


Các pain segment từ W2 được join vào audit prediction đã khóa, không retrain hoặc score lại. Bike × pickup 1–2 km có cancel rate 16,57%, Cancel PR-AUC 0,2910 và recall 25,10%; đây là cohort phù hợp để ưu tiên thiết kế can thiệp. Threshold capacity 5% vẫn giới hạn số cancel có thể bắt được, nên recall segment không nên bị diễn giải thành khả năng phát hiện toàn bộ cancel.

Segment	Số order	Cancel rate	Cancel PR-AUC	Recall tại threshold 0,27
Toàn bộ audit	8.609	9,20%	0,2709	16,41%
Pickup 1–2 km	3.109	12,96%	0,2720	20,35%
ETA 5–8 phút	1.500	14,27%	0,2747	24,77%
Khách có lịch sử hủy	5.174	10,73%	0,3009	21,08%
Bike × pickup 1–2 km	1.563	16,57%	0,2910	25,10%

8. Kết luận và artifacts tái lập

Tuần 3 đã chuyển feature engineering W2 thành một pipeline modeling có kiểm soát. Việc tách Post-Dispatch làm rõ decision point, rolling temporal validation ngăn kết luận từ một ngày test đơn lẻ, và fair HPO cho thấy CatBoost là lựa chọn tốt nhất cho metric cancel. Các hướng imbalance weighting, focal loss, weather và Transformer đều được thử nhưng không được đưa vào V3 khi không có bằng chứng cải thiện tổng thể. **Calibration vẫn là một bước bắt buộc của pipeline:** Platt scaling, Isotonic regression và SplineCalib được fit/evaluate trên tập riêng 12/07; kết quả chọn **None/raw** vì raw CatBoost tốt hơn cả ba phương án về Cancel PR-AUC, LogLoss, Brier và ECE.

V3 final đạt ROC-AUC 0,7483 và Cancel PR-AUC 0,2709 trên audit 13/07, đồng thời giảm LogLoss, Brier và ECE so với V0/W2. Bước tiếp theo không phải tune lại audit: cần xác nhận business capacity 5%, đặt SLO train/inference, và theo dõi drift, null/unseen category, calibration, alert rate/precision theo segment cùng online–offline feature parity.



Hình 9 — Dashboard MLflow dùng cho demo tiến trình W1 → W2 → W3. Sáu metric chung được hiển thị trước; confusion matrix chỉ log cho V3 vì threshold capacity 5% là policy mới của tuần 3.